1. Introdução

1.1. **Sobre o Trabalho.**

1.2. **Notação.**

1.3. **Matrizes.** Explicar o que são matrizes online e offline.

1.4. **Implementações.** Explicar os padrões que estou usando pra implementar os programas. Por exemplo: Funções como argumentos, 0-index (em contraste com o 1-index do pseudo-código) e wrappers.

2. Monotonicidade, convexidade e matrizes Monge

Aqui serão apresentados e explorados os conceitos de monotonicidade, convexidade e matrizes Monge, além disso, alguns resultados referentes a estes conceitos serão demonstrados. Estes conceitos são fundamentais para o desenvolvimento do restante do trabalho.

Definição 2.1 (Vetor monótono)**.** *Seja $a \in \mathbb{Q}^n$ um vetor, a é dito monótono quando vale uma das propriedades abaixo.*

- *Se para todo $i, j \in [n]$, $i < j \Rightarrow a_i \leq a_j$, a é dito monótono crescente (ou só crescente).*
- *Se para todo $i, j \in [n]$, $i < j \Rightarrow a_i \geq a_j$, a é dito monótono decrescente (ou só decrescente).*

Sabemos que a monotonicidade de vetores pode ser aproveitada para agilizar alguns algoritmos importantes, por exemplo, a busca binária pode ser interpretada como uma otimização da busca linear para vetores monótonos.

Definição 2.2 (Função convexa)**.** *Seja $g : \mathbb{Q} \to \mathbb{Q}$ uma função,*

- *se para todo par de pontos $x, y \in \mathbb{Q}$ e $\lambda \in \mathbb{Q}$ que respeita $0 \leq \lambda \leq 1$, vale $g(\lambda x + (1-\lambda)y) \leq \lambda g(x) + (1-\lambda)g(y)$, g é dita convexa e*
- *se para todo par de pontos $x, y \in \mathbb{Q}$ e $\lambda \in \mathbb{Q}$ que respeita $0 \leq \lambda \leq 1$, vale $g(\lambda x + (1-\lambda)y) \geq \lambda g(x) + (1-\lambda)g(y)$, g é dita côncava.*

Proposição 2.3. *A função $g(x) = x^2$ é convexa.*

Demonstração. Sejam $x, y, \lambda \in \mathbb{Q}$ onde vale $0 \leq \lambda \leq 1$. Queremos provar $(\lambda x + (1-\lambda)y)^2 \leq \lambda x^2 + (1-\lambda)y^2$, isso equivale a

$$\lambda^2 x^2 + (1-\lambda)^2 y^2 + 2\lambda(1-\lambda)xy \leq \lambda x^2 + (1-\lambda)y^2, \text{ ou seja}$$

$$(\lambda^2 - \lambda)(x^2) + ((1-\lambda)^2 - (1-\lambda))y^2 + 2(\lambda - \lambda^2)xy \leq 0, \text{ que é}$$

$$(\lambda^2 - \lambda)(x^2 + y^2 - 2xy) = (\lambda^2 - \lambda)(x+y)^2 \leq 0.$$

□

É interessante definir convexidade também em termos de vetores.

Definição 2.4 (Vetor convexo)**.** *Seja $a \in \mathbb{Q}^n$ um vetor,*

- *se para todo $i, j, k \in [n]$, $i < j < k \Rightarrow a_j \leq \frac{(j-k)a_i + (i-j)a_k}{i-k}$, a é dito convexo e*
- *se para todo $i, j, k \in [n]$, $i < j < k \Rightarrow a_j \geq \frac{(j-k)a_i + (i-j)a_k}{i-k}$, a é dito côncavo.*

Assim como a monotonicidade, a convexidade também é usualmente explorada para agilizar algoritmos, por exemplo, se um vetor é convexo podemos definir o valor mínimo do vetor com uma busca ternária ao invés de percorrer todo o vetor.

Definição 2.5. *Seja $A \in \mathbb{Q}^{n \times m}$, definimos quatro vetores a seguir.*

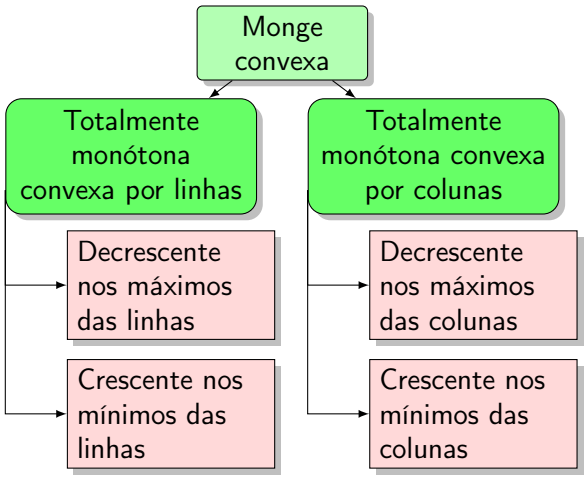

FIGURA 2.6. Comportamento dos vetores de índices ótimos em relação à convexidade.

- *O vetor de índices de máximos das linhas de A guarda na posição i o número* $\max\{j \in [m] \mid A[i][j] \geq A[i][j']$ *para todo* $j' \in [m]\}$.
- *O vetor de índices de mínimos das linhas de A guarda na posição i o número* $\min\{j \in [m] \mid A[i][j] \leq A[i][j']$ *para todo* $j' \in [m]\}$.
- *O vetor de índices de máximos das colunas de A guarda na posição j o número* $\max\{i \in [n] \mid A[i][j] \geq A[i'][j]$ *para todo* $i' \in [n]\}$.
- *O vetor de índices de mínimos das colunas de A guarda na posição j o número* $\min\{i \in [n] \mid A[i][j] \leq A[i'][j]$ *para todo* $i' \in [n]\}$.

Note que o máximo de uma linha (ou coluna) foi definido como o maior índice que atinge o máximo e o de mínimo foi definido como o menor índice que atinge o mínimo. Esta escolha foi feita para simplificar o Lema 2.9.

Dada uma matriz, encontrar estes vetores é um problema central para este trabalho. Neste momento é interessante classificar algumas matrizes de acordo com propriedades que vão nos ajudar a calcular os vetores de mínimos e máximos de maneira especialmente eficiente.

A Figura 2.6 resume as relações de implicação da classificação que será realizada. Os conceitos ilustrados nela serão apresentados a seguir.

Definição 2.7 (Matriz monótona)**.** *Seja $A \in \mathbb{Q}^{n \times m}$ uma matriz. Se A tiver o vetor de índices de máximos das linhas monótono, A é dita monótona nos máximos das linhas.*

Valem também as definições análogas para mínimos ou colunas e pode-se especificar monotonicidade crescente ou decrescente.

Definição 2.8 (Matriz totalmente monótona)**.** *Seja $A \in \mathbb{Q}^{n \times m}$ uma matriz.*

- *Se $A[i'][j] \leq A[i'][j']$ implica $A[i][j] \leq A[i][j']$ para todo $1 \leq i < i' \leq n$ e $1 \leq j < j' \leq m$, A é monótona convexa nas linhas.*

- *Se* $A[i][j'] \leq A[i'][j']$ *implica* $A[i][j] \leq A[i'][j]$ *para todo* $1 \leq i < i' \leq n$ *e* $1 \leq j < j' \leq m$, A *é monótona convexa nas colunas.*
- *Se* $A[i'][j] > A[i'][j']$ *implica* $A[i][j] > A[i][j']$ *para todo* $1 \leq i < i' \leq n$ *e* $1 \leq j < j' \leq m$, A *é monótona côncava nas linhas.*
- *Se* $A[i][j'] > A[i'][j']$ *implica* $A[i][j] > A[i'][j]$ *para todo* $1 \leq i < i' \leq n$ *e* $1 \leq j < j' \leq m$, A *é monótona côncava nas colunas.*

O motivo do uso dos termos "convexa" e "côncava" em relação a matrizes durante o texto são justificados pelo Teorema 2.15. Note que se uma matriz é totalmente monótona, todas as suas submatrizes são totalmente monótonas no mesmo sentido.

Lema 2.9. *Se* $A \in \mathbb{Q}^{n \times m}$ *é uma matriz totalmente monótona convexa nas linhas, toda submatriz de* A *é monótona decrescente nos máximos das linhas e monótona crescente nos mínimos das linhas.*

Se A *é totalmente monótona côncava nas linhas, toda submatriz de* A *é monótona decrescente nos mínimos das linhas e monótona crescente nos máximos das linhas.*

As afirmações valem identicamente em termos de colunas.

Demonstração. Considere uma matriz A totalmente monótona convexa nas linhas. Sejam i e i' índices de linhas de A onde $i < i'$. Chamamos de j o índice de máximo da linha i e de j' o índice de máximo da linha i'. Queremos provar que os máximos são decrescentes, portanto, vamos supor por absurdo que $j < j'$. Com isso, teremos $A[i][j'] < A[i][j]$ e $A[i'][j] \leq A[i'][j']$. Porém, já que A é monótona convexa nas linhas, a segunda desigualdade implica em $A[i][j] \leq A[i][j']$, que contradiz a primeira. Portanto, os índices de máximos são decrescentes.

Agora, considere novamente dois índices i e i' quaisquer de linhas de A onde $i < i'$. Denotamos por j o índice de mínimo da linha i' e por j' o índice de mínimo da linha i (note e a inversão no uso de $'$). Vamos supor por absurdo que $j < j'$ e teremos $A[i'][j] \leq A[i'][j']$ e $A[i][j'] < A[i][j]$. E, novamente, usando o fato de que A é monótona convexa nas linhas, obtivemos uma contradição.

Finalmente, se A' é uma submatriz de A, então A' é totalmente monótona convexa nas linhas, portanto monótona crescente nos máximos das linhas e monótona decrescente nos mínimos das linhas.

As demonstrações no caso côncavo e nos casos relacionados a colunas são análogas. □

Definição 2.10 (Monge Convexidade)**.** *Seja* $A \in \mathbb{Q}^{n \times m}$.

(1) *Se vale* $A[i][j] + A[i'][j'] \leq A[i][j'] + A[i'][j]$ *para todo* $1 \leq i < i' \leq n$ *e* $1 \leq j < j' \leq m$, A *é dita Monge convexa.*
(2) *Se vale* $A[i][j] + A[i'][j'] \geq A[i][j'] + A[i'][j]$ *para todo* $1 \leq i < i' \leq n$ *e* $1 \leq j < j' \leq m$, A *é dita Monge côncava.*

A desigualdade que define as matrizes Monge é conhecida também por "Condição de Monge" ou "Desigualdade Quadrangular"[4][2].

Lema 2.11. *Se A é Monge convexa, A é totalmente monótona convexa tanto nas linhas quanto nas colunas.*

Se A é Monge côncava, A é totalmente monótona côncava tanto nas linhas quanto nas colunas.

Demonstração. Seja A uma matriz Monge convexa. Suponha que vale, para certos $i, i' \in [n]$ e $j, j' \in [m]$ onde $i < i'$ e $j < j'$, $A[i'][j] \leq A[i'][j']$, então, somamos esta desigualdade à definição de Monge convexa e obtemos $A[i][j] \leq A[i][j']$, ou seja, A é totalmente monótona convexa nas linhas.

Por outro lado, se vale, para certos $i, i' \in [n]$ e $j, j' \in [m]$ com $i < i'$ e $j < j'$, $A[i][j'] \leq A[i'][j']$, somamos esta desigualdade à definição de Monge convexa e obtemos $A[i][j] \leq A[i'][j]$, assim, A é totalmente monótona convexa nas colunas.

A prova para o caso côncavo é análoga. □

As matrizes Monge são usadas para resolver uma série de problemas que serão explorados aqui. A condição de Monge é a mais forte apresentada aqui. Alguns dos algoritmos apresentados não dependem dela, apenas da monotonicidade ou total monotonicidade, ainda assim, ela leva a resultados úteis que nos permitem provar a pertinência dos algoritmos a alguns problemas, mesmo que o algoritmo usado não se utilize da condição diretamente.

Como consequência desta utilidade, iremos discutir um problema que será resolvido com um algoritmo apresentado somente na Seção 4, o algoritmo SMAWK. Ele não será explicado neste momento, utilizamos ele como caixa preta. Isto é motivado pelo fato de que o pensamento apresentado aqui não é útil somente para o algoritmo SMAWK, ele é útil também em vários dos outros momentos deste trabalho.

Problema 2.12. *Dados dois inteiros k e n com $k \leq n$, um vetor de pesos $a \in \mathbb{Q}_+^n$ e uma matriz de custos $A[i][j] = \left(\sum_{k=i+1}^{j} a_k\right)^2$. Queremos particionar o vetor a em k partes não-vazias de forma a maximizar a soma dos custos das partes, isto é, queremos escolher um vetor $r \in \mathbb{N}^{[0\,..\,k]}$ de índices tal que $1 = r_0 < r_1 < r_2 < \cdots < r_{k-1} < r_k = n$ de forma que $\sum_{i=1}^{k} A[r_{i-1}][r_i]$ seja máximo.*

Podemos resolver este problema com programação dinâmica. Vamos preencher a matriz $E \in \mathbb{Q}^{k \times n}$ definida recursivamente para todo $k' \in [k]$ e $n' \in [n]$:

$$E[k'][n'] = \begin{cases} A[1][n'] & \text{, se } k' = 1, \\ \max_{i=k'-1}^{n'-1} E[k'-1][i] + A[i][n'] & \text{, se } k' \leq n', \\ \text{indefinida} & \text{, caso contrário.} \end{cases}$$

A recorrência acima nos dá em cada entrada $E[k'][n']$ o maior valor possível alcançado particionando o vetor $a[1\,..\,n']$ em k' partes não vazias. Podemos

preencher esta tabela trivialmente em tempo $O(kn^2)$, basta iterarar primeiro pelos índices k' crescentemente. O caso onde $k' = 1$ é resolvido trivialmente e os casos maiores podem ser resolvidos, um por vez, testando todas as possibilidades de máximo para todo n'.

Fixamos um $k' > 1$. Vamos utilizar o algoritmo SMAWK para agilizar a solução deste subproblema. Este algoritmo é capaz de resolver o Problema 2.13 (descrito abaixo) em tempo $O(n)$. Precisamos provar, então, que o subproblema resolvido para cada k' é equivalente ao Problema 2.13.

Problema 2.13. *Dada uma matriz $A \in \mathbb{A}^{n\times n}$ totalmente monótona convexa nas colunas, encontrar o vetor de máximos das colunas de A.*

Definimos a matriz $B_{k'}$ para todo $i, n' \in \mathbb{N}$ onde $k' - 1 \leq i < n' \leq n$ como $B_{k'}[i][n'] = E[k' - 1][i] + A[i][n']$. Note que já que k' é fixo, já descobrimos os valores da entrada da matriz E na linha $k' - 1$. Encontrar o índice i que atinge o máximo em $E[k'][n']$ é exatamente encontrar o índice de máximo da coluna n' na matriz $B_{k'}$, formalmente,

$$\max_{i=k'-1}^{n'-1} B_{k'}[i][n'] = \max_{i=k'-1}^{n'-1} E[k' - 1][i] + A[i][n'].$$

Portanto, basta mostrar que $B_{k'}$ é monótona convexa nas colunas. Para isso, vamos mostrar, com a ajuda dos resultados abaixo, que $B_{k'}$ é Monge convexa.

Lema 2.14. *Sejam $A, B \in \mathbb{Q}^{n\times m}$ matrizes e $c \in \mathbb{Q}^n$ um vetor tais que para todo $i \in [n]$ e $j \in [m]$, $B[i][j] = A[i][j] + c[i]$. Se A é Monge convexa, B é Monge convexa.*

O mesmo resultado vale se $c \in \mathbb{Q}^m$ e $B[i][j] = A[i][j] + c[j]$.

Demonstração. Sejam A, B e b definidos como no enunciado do teorema. Suponha que A é Monge convexa. Vale, para quaisquer $1 \leq i < i' \leq n$ e $1 \leq j < j' \leq m$, $A[i][j] + A[i'][j'] \leq A[i'][j] + A[i][j']$, logo, vale $A[i][j] + b[i] + A[i'][j'] + b[i'] \leq A[i'][j] + b[i'] + A[i][j'] + b[i]$ que é $B[i][j] + B[i'][j'] \leq B[i'][j] + B[i][j']$. A prova para o caso onde $c \in \mathbb{Q}^m$ e $B[i][j] = A[i][j] + c[j]$ é análoga. □

Com este resultado, é fácil ver que, desde que A seja Monge convexa, B_1 será Monge convexa e a Monge convexidade será mantida para todo $B_{k'}$ com $1 \leq k' \leq k$. O teorema a seguir nos ajuda a mostrar que A é Monge convexa.

Teorema 2.15. *Sejam $A \in \mathbb{Q}^{n\times n}$ uma matriz, $w \in \mathbb{Q}_+^n$ um vetor e $g : \mathbb{Q} \to \mathbb{Q}$ uma fução tais que para todo $i, j \in [n]$ vale $A[i][j] = g\left(\sum_{k=1}^{j} w_k - \sum_{k=1}^{i} w_k\right)$. Se g é convexa, A é Monge convexa. Similarmente, se g é côncava, A é Monge côncava.*

Antes de apresentar uma prova para o teorema acima, vamos mostrar a utilidade dele no nosso problema atual, o que deve ajudar na compreensão de seu enunciado.

Queremos mostrar que A é Monge convexa, porém, para um certo vetor $a \in \mathbb{Q}_+^n$, $A[i][j] = \left(\sum_{k=(i+1)}^{j} a_k \right)^2 = \left(\sum_{k=1}^{j} a_k - \sum_{k=1}^{i} a_k \right)^2$, por definição. Assim, precisamos mostrar apenas que a função $g(x) = x^2$ é convexa, o que segue da Proposição 2.3. Agora, como explicado acima, todas as matrizes $B_{k'}$ são Monge convexas e podemos aplicar o algoritmo SMAWK para todo k', resolvendo o Problema 2.12 em tempo $O(kn)$.

Agora, nos resta provar o Teorema 2.15.

Demonstração. Sejam A e g quaisquer que respeitem as condições do enunciado. Sejam ainda $i, i', j, j' \in [n]$ onde $i < i'$ e $j < j'$. Escrevemos $a = \sum_{k=1}^{i'} w_k - \sum_{k=1}^{i} w_k$, $b = \sum_{k=1}^{j'} w_k - \sum_{k=1}^{j} w_k$ e $z = \sum_{k=1}^{j} w_k - \sum_{k=1}^{i'} w_k$. Desta forma, temos $g(z) = A[i'][j]$, $g(z+a+b) = A[i][j']$, $g(z+a) = A[i][j]$ e $g(z+b) = A[i'][j']$, portanto, $g(z+a) + g(z+b) \leq g(z) + g(z+a+b)$ se e somente se $A[i][j] + A[i'][j'] \leq A[i][j'] + A[i'][j]$ (A é Monge convexa).

Com isso, vamos provar que se g é convexa, A é Monge convexa. Sejam $i, i', j, j' \in [n]$ onde $i < i'$ e $j < j'$. Definimos a, b e z como acima. Sabemos $0 \leq a$ e $0 \leq b$. Consideramos o caso onde $0 < a \leq b$. Temos $0 < a \leq b < a + b$, ou seja, $z < z + a \leq z + b < z + a + b$. Definimos $\lambda = \frac{a}{a+b}$. Já que $z + a = \lambda z + (1 - \lambda)(z + a + b)$ e $z + b = (1 - \lambda)z + \lambda(z + a + b)$, por convexidade de g, obtemos $g(z + a) \leq \lambda g(z) + (1 - \lambda)g(z + a + b)$ e $g(z+b) \leq \lambda g(z+a+b)+(1-\lambda)g(z)$. Somando, obtemos $g(z+a)+g(z+b) \leq g(z) + g(z + a + b)$.

Se considerarmos o caso onde $0 < b \leq a$, seguimos o mesmo raciocínio e obtemos, novamente, $g(z+a)+g(z+b) \leq g(z)+g(z+a+b)$. Falta considerar o caso onde $0 = a = b$, neste caso, $g(z) = g(z+a) = g(z+b) = g(z+a+b)$ e vale $(z+a)+g(z+b) \leq g(z)+g(z+a+b)$. Portanto, A é Monge convexa. □

3. Divisão e Conquista

eu tenho que citar algo aqui?

Nesta seção será apresentada uma técnica que chamamos de Divisão e Conquista. A ideia é citada em [**?**] e é um tópico recorrente em competições de programação, sendo conhecida como "Divide and Conquer Optimization"e geralmente aplicada a problemas de programação dinâmica. Além disso, as hipóteses deste algoritmo são mais fracas do que as do algoritmo SMAWK, apresentado na Seção 4, portanto, todo problema para o qual aquela solução pode ser aplicada, esta também pode. Ao final desta seção, apresentamos exemplos de aplicações em programação dinâmica.

Dada uma matriz $A \in \mathbb{Q}^{n\times m}$, listamos os casos de uso deste algoritmo:

- Se A é monótona crescente nos mínimos das linhas podemos encontrar os índices de mínimos das linhas em tempo $\mathcal{O}((n+m)\lg(n))$,
- se A é monótona decrescente nos mínimos das linhas podemos encontrar os índices de mínimos das linhas em tempo $\mathcal{O}((n+m)\lg(n))$,
- se A é monótona crescente nos máximos das linhas podemos encontrar os índices de máximos das linhas em tempo $\mathcal{O}((n+m)\lg(n))$,
- se A é monótona decrescente nos máximos das linhas podemos encontrar os índices de máximos das linhas em tempo $\mathcal{O}((n+m)\lg(n))$,
- se A é monótona crescente nos mínimos das colunas podemos encontrar os índices de mínimos das colunas em tempo $\mathcal{O}((n+m)\lg(m))$,
- se A é monótona decrescente nos mínimos das colunas podemos encontrar os índices de mínimos das colunas em tempo $\mathcal{O}((n+m)\lg(m))$,
- se A é monótona crescente nos máximos das colunas podemos encontrar os índices de máximos das colunas em tempo $\mathcal{O}((n+m)\lg(m))$ e
- se A é monótona decrescente nos máximos das colunas podemos encontrar os índices de máximos das colunas em tempo $\mathcal{O}((n+m)\lg(m))$.

Apresentaremos o caso em que A é crescente nos mínimos das linhas. Na Subseção 3.4 explicamos como reduzir os problemas elencados para este caso.

3.1. **Técnica.** Dada uma matriz $A \in \mathbb{Q}^{n\times m}$ monótona crescente nos máximos das linhas, queremos encontrar o vetor de índices de máximos das linhas de A. Isto é, para todo $i \in [n]$, queremos encontrar

$$R[i] = \min\{j \mid A[i][j] \geq A[i][j'] \text{ para todo } j' \in [n]\}.$$

Se, para alguma linha i, encontrarmos o valor $R[i]$, sabemos, já que A é monótona convexa, que para todo $i' < i$, $R[i'] \leq R[i]$ e, para todo $i' > i$, $R[i'] \geq R[i]$, isto é, sabemos que os máximos de menor índice das outras linhas se encontram nas submatrizes $A[1\,..\,i-1][1\,..\,R[i]]$ e $A[i+1\,..\,n][R[i]\,..\,m]$. Basta, agora, seguindo o paradigma de divisão e conquista, resolver o mesmo problema para estas submatrizes e conseguimos resolver o problema original.

Algoritmo 3.1 Máximos das linhas com divisão e conquista

```
1: função FindRowMax_DC(A, r_s, r_t, c_s, c_t)
2:     ℓ ← ⌈(r_s + r_t)/2⌉
3:     R[ℓ] ← min{j | A[i][j] ≥ A[i][j'] para todo j' ∈ [c_s .. c_t]}
4:     se i > r_s então
5:         R[r_s .. ℓ − 1] ← FindRowMax_DC(A, r_s, ℓ − 1, c_s, R[ℓ])
6:     se i < r_t então
7:         R[ℓ + 1 .. r_t] ← FindRowMax_DC(A, ℓ + 1, r_t, R[ℓ], c_t)
8:     devolve R
```

3.2. **Análise.** Será feita uma análise do tempo de execução do algoritmo acima no pior caso assumindo que as atribuições feitas nas linhas 5 e 7 custam tempo constante, futuramente, em 3.3, iremos apresentar uma implementação em C++ que está de acordo com a análise realizada.

Se A é uma matriz e r_s, r_t, c_s e c_t são índices tais que $r_t - r_s = n > 0$ e $c_t - c_s = m > 0$, o tempo gasto por FindRowMax_DC(A, r_s, r_t, c_s, c_t) pode ser expresso pela seguinte recorrência:

$$T(n,m) = \begin{cases} m & \text{, se } n = 1, \\ m + \max\limits_{j\in[m]} T(1,j) & \text{, se } n = 2, \\ m + \max\limits_{j\in[m]} \left\{ \begin{array}{c} T(\lceil n/2\rceil - 1, m-j+1) \\ +T(\lfloor n/2\rfloor, j) \end{array} \right\} & \text{, caso contrário.} \end{cases}$$

Proposição 3.2. *Para todo $n, m \geq 1$, $T(n,m) \leq (m+n)\lg(2n)$ e, portanto, a técnica da divisão e conquista consegue encontrar o máximo de todas as linhas em tempo $\mathcal{O}((m+n)\lg(n))$*

Demonstração. Vamos usar indução em n para provar a tese. Se $n = 1$ e $m \geq 1$, $T(1,m) = m \leq (m+1)\lg(2)$. Se $n = 2$ e $m \geq 1$, existe $j \in [m]$ tal que $T(2,m) = m + r \leq 2m \leq (m+2)\lg(4)$. Agora, se $n \geq 3$ e $m \geq 1$, existe um $j \in [m]$ tal que

$$T(n,m) = m + T(\lceil n/2\rceil - 1, j) + T(\lfloor n/2\rfloor, m - j + 1).$$

Assumimos para $1 \leq n' < n$ e $m' \geq 1$ que $T(n',m') \leq (m'+n')\lg(2n')$. Com isso, já que $1 \leq \lceil n/2\rceil - 1 < n$, $1 \leq \lfloor n/2\rfloor < n$, $j \geq 1$ e $m - j + 1 \geq 1$, temos, com a equação acima e o fato de que $\lceil n/2\rceil - 1 \leq \lfloor n/2\rfloor \leq n/2$,

$$\begin{aligned} T(n,m) &\leq m + (j + \lceil n/2\rceil - 1 + m - j + 1 + \lfloor n/2\rfloor)\lg(n) \\ &= m + (m+n)\lg(n) < (m+n)(\lg(n)+1) = (m+n)\lg(2n). \end{aligned}$$

□

3.3. **Implementação.** Para implementar o Algoritmo 3.1 com a complexidade desejada, devemos tomar cuidado com as atribuições feitas nas linhas 5 e 7. A forma como elas foram apresentadas sugere que os vetores R recebidos pelas funções sejam recebidos e copiados para o vetor R. Ao invés de fazer isso, passaremos o endereço do vetor R recursivamente e garantir

que cada chamada só complete o subvetor $R[r_c \,..\, r_t]$, referente a seu subproblema. Além disso, como explicado na Seção 1.4, a matriz A será passada como uma função e não como uma matriz.

A implementação em C++ do algoritmo apresentado, levando em conta as considerações acima, pode ser encontrada em `implementacao/FindRowMax_DC.cpp`.

Isso é chato de ser escrito, não basta transformar a matriz e usar as coisas como caixa preta por causa da forma como índices de máximos e mínimos foram definidos

3.4. **Generalizações.**

4. SMAWK

Nesta seção discutiremos o algoritmo SMAWK. Ele é conhecido pela sua aplicação no problema de encontrar o vértice mais distante de cada vértice num poígono convexo em tempo linear [1]. Ao final desta seção serão explicadas esta e outras aplicações deste algoritmo.

Dada uma matriz $A \in \mathbb{Q}^{n \times m}$, listamos os casos de uso deste algoritmo:

- Se A é totalmente monótona convexa ou côncava nas linhas podemos encontrar os índices de mínimos e máximos das linhas em tempo $\mathcal{O}(n + m)$ e
- se A é totalmente monótona convexa ou côncava nas colunas podemos encontrar os índices de mínimos e máximos das colunas em tempo $\mathcal{O}(n + m)$.

Apresentaremos o caso onde A é totalmente monótona convexa nas linhas e estamos interessados nos índices de mínimos. Na Subseção 4.6 explicamos como reduzir os problemas elencados para este caso.

4.1. **Técnica Primordial.** Para facilitar a compreensão do algoritmo SMAWK, iremos apresentar uma técnica parecida com a Divisão e Conquista apresentada na Seção 3 e mostrar uma otimização desta técnica que leva ao algoritmo SMAWK.

Dada uma matriz $A \in \mathbb{Q}^{n \times m}$ totalmente monótona convexa por linhas, queremos encontrar o menor índice de mínimo de cada uma das linhas de A. Se para uma dada linha i onde $i > 0$ e $i < n$ conhecermos os índices l e r de mínimos das linhas $i - 1$ e $i + 1$, respectivamente, já que A tem os índices de mínimos das linhas crescente (por ser totalmente monótona) basta buscar o índice de mínimo da linha i no intervalo entre l e r (inclusive). Além disso, se i é a primeira linha da matriz podemos considerar $l = 1$ ou se i é a última linha da matriz podemos considerar $r = n$ sem perder a validade do fato de que basta buscar entre l e r.

Após realizar as observações acima note que, já que A é totalmente monótona, remover qualquer linha de A mantém a total monotonicidade e não altera o índice de mínimo de outra linha. Com esta observação, concluímos que podemos remover todas as linhas pares da matriz, resolver o problema recursivamente para a matriz resultante e utilizar este resultado para calcular os índices de interessa para as linhas pares da matriz.

Com uma análise similar à realizada para a técnica da Divisão e Conquista é fácil concluir que uma implementação desta técnica que consiga remover as linhas pares da matriz (e adicionar elas de volta) em tempo $\mathcal{O}(1)$ resolve o problema em tempo $\mathcal{O}((n + m) \lg(n))$, assim como a técnica da divisão e conquista.

4.2. **Reduce.** Queremos agilizar a técnica apresentada acima. Para isso, vamos adicionar uma nova hipótese. Vamos supor que a matriz A é quadrada, ou seja, $n = m$. Lembre que a cada passo, removemos as $\lfloor n/2 \rfloor$ linhas pares da matriz gerando uma nova matriz A', resolvemos o problema

recursivamente para A' e usamos a solução de A' para resolver para as linhas restantes de A. O problema é que quando removemos linhas da nossa A, ela deixa de ser quadrada e passa a ser uma matriz com mais colunas do que linhas, isto é, $m \geq n$. Chamamos de ótimas as células da matriz que são mínimo de alguma linha e as colunas que contém o índice de mínimo de pelo menos uma linha. Note que uma matriz contém no máximo n colunas ótimas, pois cada linha faz com que exatamente uma célula seja ótima. Queremos remover colunas não ótimas de uma matriz A com mais colunas do que linhas fazendo com que A se torne quadrada.

Vamos desenvolver o algoritmo REDUCE a partir de um índice de linha $k \leq n$ e de uma invariante: Toda célula com índices de linha menor do que k e coluna menor ou igual a k não é ótima. Se o índice k representa uma coluna, a invariante nos diz que todas as células acima da diagonal principal que estão nesta coluna ou à esquerda dela são não ótimas. A Figura 4.1 representa, em azul, a célula de índice k, k e, em preto, as células que, segundo a invariante, são não ótimas.

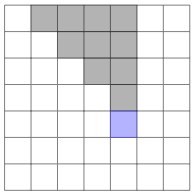

FIGURA 4.1. Invariante do REDUCE.

Primeiramente, se $k \leq n$ e a entrada $A[k][k+1]$ não existir na matriz, ela não tem mais colunas do que linhas e não precisamos aplicar o REDUCE. Se $A[k][k] > A[k][k+1]$, toda a coluna k é não ótima e pode ser removida. Para demonstrar isso, escolhemos um índice de linha i qualquer e mostramos que $A[i][k]$ é não ótimo. Se $i < k$ o fato segue da invariante e se $i = k$ também é verdade pois $A[k][k+1]$ pertence à mesma linha e tem valor estritamente menor. Agora, se $i > k$, pela definição de total monotonicidade temos $A[i][k] \leq A[i][k+1]$ implica $A[k][k] \leq A[k][k+1]$, basta aplicar a contrapositiva nesta afirmação e observar que $A[i][k] > A[i][k+1]$, portanto $A[i][k]$ também é não ótima. Note que se removermos a coluna k da matriz e não alterarmos o índice k, a invariante não será mantida, basta subtrair 1 de k para manter a invariante.

Agora, se $A[k][k] \leq A[k][k+1]$, vamos mostrar que todos os elementos da coluna $k+1$ que estão em uma linha maior ou igual à k-ésima são não ótimos.

4.3. **SMAWK.**

4.4. **Análise.**

4.5. **Implementação.**

4.6. **Generalizações.**

Referências

[1] Alok Aggarwal, Maria M. Klawe, Shlomo Moran, Peter Shor, and Robert Wilber. Geometric applications of a matrix-searching algorithm. *Algorithmica*, 2(1):195–208, 1987.

[2] Wolfgang Bein, Mordecai J. Golin, Lawrence L. Larmore, and Yan Zhang. The knuth-yao quadrangle-inequality speedup is a consequence of total monotonicity. *ACM Trans. Algorithms*, 6(1):17:1–17:22, December 2009.

[3] Zvi Galil and Kunsoo Park. Dynamic programming with convexity, concavity and sparsity. *Theoretical Computer Science*, 92(1):49 – 76, 1992.

[4] F. Frances Yao. Efficient dynamic programming using quadrangle inequalities. In *Proceedings of the Twelfth Annual ACM Symposium on Theory of Computing*, STOC '80, pages 429–435, New York, NY, USA, 1980. ACM.