

1. PROPOSTA

As matrizes Monge têm propriedades como a monotonicidade total e a monotonicidade, que são exploradas por uma série de algoritmos para a busca de máximos e mínimos em linhas e colunas destas matrizes. Algumas destas técnicas são populares pois são utilizadas para a agilização de problemas clássicos e aparecem com crescente frequência em competições de programação por sua utilidade na solução eficiente de problemas de programação dinâmica.

Busca-se neste trabalho formalizar, compilar e aprofundar os conhecimentos adquiridos sobre estes algoritmos por meio do estudo da literatura já existente [8] [4] a fim de facilitar o aprendizado destas técnicas. Além disso, procura-se generalizar os algoritmos inspirando-se em desafios propostos em competições, explorando suas limitações e modificando as formalizações encontradas na literatura para ampliar os escopos tradicionais. Serão disponibilizadas, também, implementações eficientes dos algoritmos estudados que sejam utilizáveis em diversos cenários. Serão criados e fornecidos testes para comparar as velocidades delas quando possível.

1.1. Cronograma. Algumas das atividades planejadas já foram realizadas. Durante os meses de Janeiro e Fevereiro foi realizado um estudo inicial da bibliografia, em Fevereiro e Março foi escrita a Seção 3 sobre a técnica da divisão e conquista, durante Março e Abril foi desenvolvida a Seção 2 sobre matrizes Monge e convexidade e a Seção 4 sobre o algoritmo SMAWK foi produzida durante o mês de Abril. Durante os meses de Maio e Junho, o estudaremos buscas de máximos e mínimos em matrizes online [8] [5] e, depois disso, ainda em Junho será explorada a otimização de Knuth-Yao [4] [9] [10]. Após estudar estes algoritmos e suas aplicações, serão estudadas as possíveis generalizações deles. Em Julho e Agosto, olharemos para os algoritmos sobre matrizes online já explorados sob o ponto de vista da dualidade pontoreta [7], em Agosto e Setembro exploramos condições mais fracas para a busca em matrizes online e em Setembro e Outubro revisitamos a otimização de Knuth-Yao buscando, também, enfraquecer as condições para sua aplicação. Durante quase todo o desenvolvimento do trabalho, de Fevereiro até Outubro, serão implementados e testados os algoritmos discutidos. Finalmente, o mês de Novembro será reservado para a finalizar e preparar a apresentação do trabalho.

1.2. Texto atual. No que segue, apresentaremos parte da pesquisa já realizada. O nosso objetivo neste projeto é continuar o estudo nesta linha.

:q cclear
:visual

2. MATRIZES MONGE E MONOTONICIDADE

Nesta seção serão apresentados e explorados os conceitos de monotonicidade, convexidade e matrizes Monge, além disso, alguns resultados referentes a estes conceitos serão demonstrados. As definições e os resultados desta seção são fundamentais para o desenvolvimento do restante do trabalho.

Definição 2.1 (Vetor monótono). *Seja $a \in \mathbb{Q}^n$ um vetor, a é dito monótono quando vale uma das propriedades abaixo.*

- Se para todo $i, j \in [n]$, $i < j \Rightarrow a_i \leq a_j$, a é dito monótono crescente (ou só crescente).
- Se para todo $i, j \in [n]$, $i < j \Rightarrow a_i \geq a_j$, a é dito monótono decrescente (ou só decrescente).

Sabemos que a monotonicidade de vetores pode ser aproveitada para agilizar alguns algoritmos importantes, por exemplo, a busca binária pode ser interpretada como uma otimização da busca linear para vetores monótonos.

Definição 2.2 (Função convexa). *Seja $g : \mathbb{Q} \rightarrow \mathbb{Q}$ uma função,*

- se para todo par de pontos $x, y \in \mathbb{Q}$ e $\lambda \in \mathbb{Q}$ que respeita $0 \leq \lambda \leq 1$, vale $g(\lambda x + (1 - \lambda)y) \leq \lambda g(x) + (1 - \lambda)g(y)$, g é dita convexa e
- se para todo par de pontos $x, y \in \mathbb{Q}$ e $\lambda \in \mathbb{Q}$ que respeita $0 \leq \lambda \leq 1$, vale $g(\lambda x + (1 - \lambda)y) \geq \lambda g(x) + (1 - \lambda)g(y)$, g é dita côncava.

Proposição 2.3. *A função $g(x) = x^2$ é convexa.*

Demonstração. Sejam $x, y, \lambda \in \mathbb{Q}$ onde vale $0 \leq \lambda \leq 1$. Queremos provar $(\lambda x + (1 - \lambda)y)^2 \leq \lambda x^2 + (1 - \lambda)y^2$, isso equivale a

$$\begin{aligned} \lambda^2 x^2 + (1 - \lambda)^2 y^2 + 2\lambda(1 - \lambda)xy &\leq \lambda x^2 + (1 - \lambda)y^2, \text{ ou seja} \\ (\lambda^2 - \lambda)(x^2) + ((1 - \lambda)^2 - (1 - \lambda))y^2 + 2(\lambda - \lambda^2)xy &\leq 0, \text{ que é} \\ (\lambda^2 - \lambda)(x^2 + y^2 - 2xy) &= (\lambda^2 - \lambda)(x + y)^2 \leq 0. \end{aligned}$$

□

É interessante definir convexidade também em termos de vetores.

Definição 2.4 (Vetor convexo). *Seja $a \in \mathbb{Q}^n$ um vetor,*

- se para todo $i, j, k \in [n]$, $i < j < k \Rightarrow a_j \leq \frac{(j-k)a_i + (i-j)a_k}{i-k}$, a é dito convexo e
- se para todo $i, j, k \in [n]$, $i < j < k \Rightarrow a_j \geq \frac{(j-k)a_i + (i-j)a_k}{i-k}$, a é dito côncavo.

Assim como a monotonicidade, a convexidade também é usualmente explorada para agilizar algoritmos, por exemplo, se um vetor é convexo podemos definir o valor mínimo do vetor com uma busca ternária ao invés de percorrer todo o vetor.

Definição 2.5. *Seja $A \in \mathbb{Q}^{n \times m}$, definimos quatro vetores a seguir.*

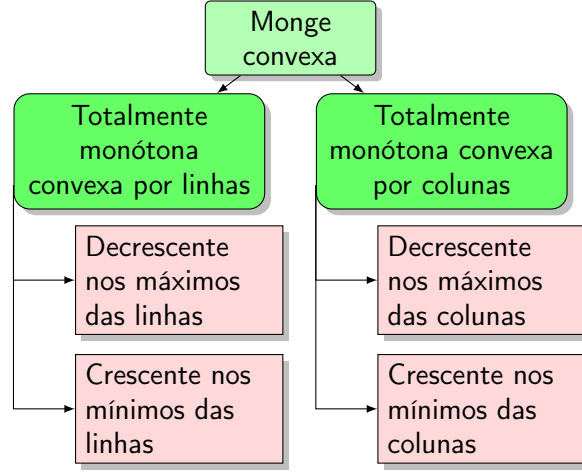


FIGURA 2.6. Comportamento dos vetores de índices ótimos em relação à convexidade.

- O vetor de índices de máximos das linhas de A guarda na posição i o número $\max\{j \in [m] \mid A[i][j] \geq A[i][j'] \text{ para todo } j' \in [m]\}$.
- O vetor de índices de mínimos das linhas de A guarda na posição i o número $\min\{j \in [m] \mid A[i][j] \leq A[i][j'] \text{ para todo } j' \in [m]\}$.
- O vetor de índices de máximos das colunas de A guarda na posição j o número $\max\{i \in [n] \mid A[i][j] \geq A[i'][j] \text{ para todo } i' \in [n]\}$.
- O vetor de índices de mínimos das colunas de A guarda na posição j o número $\min\{i \in [n] \mid A[i][j] \leq A[i'][j] \text{ para todo } i' \in [n]\}$.

Note que o máximo de uma linha (ou coluna) foi definido como o maior índice que atinge o máximo e o de mínimo foi definido como o menor índice que atinge o mínimo. Esta escolha foi feita para simplificar o Lema 2.9, porém, os algoritmos e resultados discutidos neste trabalho funcionam (com pequenas adaptações) para diversas definições distintas destes vetores.

Dada uma matriz, encontrar estes vetores é um problema central para este trabalho. Neste momento é interessante classificar algumas matrizes de acordo com propriedades que vão nos ajudar a calcular os vetores de mínimos e máximos de maneira especialmente eficiente.

A Figura 2.6 resume as relações de implicação da classificação que será realizada. Os conceitos ilustrados nela serão apresentados a seguir.

Definição 2.7 (Matriz monótona). *Seja $A \in \mathbb{Q}^{n \times m}$ uma matriz. Se A tiver o vetor de índices de mínimos das linhas monótono, A é dita monótona nos mínimos das linhas.*

Valem também as definições análogas para máximos ou colunas e pode-se especificar monotonicidade crescente ou decrescente.

Definição 2.8 (Matriz totalmente monótona). *Seja $A \in \mathbb{Q}^{n \times m}$ uma matriz.*

- Se $A[i'][j] \leq A[i'][j']$ implica $A[i][j] \leq A[i][j']$ para todo $i, i' \in [n]$ e $j, j' \in [m]$ onde $i < i'$ e $j < j'$, A é monótona convexa nas linhas.
- Se $A[i][j'] \leq A[i'][j']$ implica $A[i][j] \leq A[i'][j]$ para todo $i, i' \in [n]$ e $j, j' \in [m]$ onde $i < i'$ e $j < j'$, A é monótona convexa nas colunas.
- Se $A[i'][j] > A[i'][j']$ implica $A[i][j] > A[i][j']$ para todo $i, i' \in [n]$ e $j, j' \in [m]$ onde $i < i'$ e $j < j'$, A é monótona côncava nas linhas.
- Se $A[i][j'] > A[i'][j']$ implica $A[i][j] > A[i'][j]$ para todo $i, i' \in [n]$ e $j, j' \in [m]$ onde $i < i'$ e $j < j'$, A é monótona côncava nas colunas.

O motivo do uso dos termos “convexa” e “côncava” em relação a matrizes durante o texto são justificados pelo Teorema 2.15. Note que se uma matriz é totalmente monótona, todas as suas submatrizes são totalmente monótonas no mesmo sentido.

Lema 2.9. *Se $A \in \mathbb{Q}^{n \times m}$ é uma matriz totalmente monótona convexa nas linhas, toda submatriz de A é monótona crescente nos mínimos das linhas e monótona decrescente nos máximos das linhas.*

Se A é totalmente monótona côncava nas linhas, toda submatriz de A é monótona decrescente nos mínimos das linhas e monótona crescente nos máximos das linhas.

As afirmações valem identicamente em termos de colunas.

Demonstração. Considere uma matriz A totalmente monótona convexa nas linhas. Sejam i e i' índices de linhas de A onde $i < i'$. Chamamos de j o índice de máximo da linha i e de j' o índice de máximo da linha i' . Queremos provar que os máximos são decrescentes, portanto, vamos supor por absurdo que $j < j'$. Com isso, teremos $A[i][j'] < A[i][j]$ e $A[i'][j] \leq A[i'][j']$. Porém, já que A é monótona convexa nas linhas, a segunda desigualdade implica em $A[i][j] \leq A[i][j']$, que contradiz a primeira. Portanto, os índices de máximos são decrescentes.

Agora, considere novamente dois índices i e i' quaisquer de linhas de A onde $i < i'$. Denotamos por j o índice de mínimo da linha i' e por j' o índice de mínimo da linha i (note e a inversão no uso de $'$). Vamos supor por absurdo que $j < j'$ e teremos $A[i'][j] \leq A[i'][j']$ e $A[i][j'] < A[i][j]$. E, novamente, usando o fato de que A é monótona convexa nas linhas, obtivemos uma contradição.

Finalmente, se A' é uma submatriz de A , então A' é totalmente monótona convexa nas linhas, portanto monótona crescente nos mínimos das linhas e monótona decrescente nos máximos das linhas.

As demonstrações no caso côncavo e nos casos relacionados a colunas são análogas. \square

Definição 2.10 (Monge Convexidade). *Seja $A \in \mathbb{Q}^{n \times m}$.*

- (1) *Se vale $A[i][j] + A[i'][j'] \leq A[i][j'] + A[i'][j]$ para todo $i, i' \in [n]$ e $j, j' \in [m]$ onde $i < i'$ e $j < j'$ então A é dita Monge convexa.*
- (2) *Se vale $A[i][j] + A[i'][j'] \geq A[i][j'] + A[i'][j]$ para todo $i, i' \in [n]$ e $j, j' \in [m]$ onde $i < i'$ e $j < j'$ então A é dita Monge côncava.*

A desigualdade que define as matrizes Monge é conhecida pelos nomes “Propriedade de Monge” (em inglês, “Monge Property”) [6] ou “Desigualdade Quadrangular” (em inglês, “Quadrangle Inequality”)[10][4].

Lema 2.11. *Se A é Monge convexa, A é totalmente monótona convexa tanto nas linhas quanto nas colunas.*

Se A é Monge côncava, A é totalmente monótona côncava tanto nas linhas quanto nas colunas.

Demonstração. Seja A uma matriz Monge convexa. Suponha que vale, para certos $i, i' \in [n]$ e $j, j' \in [m]$ onde $i < i'$ e $j < j'$, $A[i'][j] \leq A[i][j']$, então, somamos esta desigualdade à definição de Monge convexa e obtemos $A[i][j] \leq A[i][j']$, ou seja, A é totalmente monótona convexa nas linhas.

Por outro lado, se vale, para certos $i, i' \in [n]$ e $j, j' \in [m]$ com $i < i'$ e $j < j'$, $A[i][j'] \leq A[i'][j']$, somamos esta desigualdade à definição de Monge convexa e obtemos $A[i][j] \leq A[i'][j]$, assim, A é totalmente monótona convexa nas colunas.

A prova para o caso côncavo é análoga. \square

Teorema 2.12. *Seja $A \in \mathbb{Q}^{n \times m}$.*

Vale $A[i][j] + A[i+1][j+1] \leq A[i][j+1] + A[i+1][j]$ para todo $i \in [n-1]$ e $j \in [m-1]$ se e somente se A é Monge convexa.

Vale $A[i][j] + A[i+1][j+1] \geq A[i][j+1] + A[i+1][j]$ para todo $i \in [n-1]$ e $j \in [m-1]$ se e somente se A é Monge côncava.

Demonstração. Seja $A \in \mathbb{Q}^{n \times m}$. Se A é Monge convexa, vale $A[i][j] + A[i+1][j+1] \leq A[i][j+1] + A[i+1][j]$ para todo $i \in [n-1]$ e $j \in [m-1]$. Vamos mostrar o outro lado desta implicação.

Sejam $i \in [n-1]$ e $j \in [m-1]$ quaisquer, vamos provar que $A[i][j] + A[i+a][j+1] \leq A[i][j+1] + A[i+a][j]$ para todo $0 < a \leq n-i$ com indução em a . A base, onde $a=1$ vale pela hipótese. Quando $1 < a \leq n-i$ assumimos que a tese vale com $a-1$ e temos $A[i][j] + A[i+a-1][j+1] \leq A[i][j+1] + A[i+a-1][j]$ e, já que $i+a-1 \in [n-1]$, vale $A[i+a-1][j] + A[i+a][j+1] \leq A[i+a-1][j+1] + A[i+a][j]$ e, somando as duas inequações, obtemos $A[i][j] + A[i+a][j+1] \leq A[i][j+1] + A[i+a][j]$. Isso conclui a prova proposta neste parágrafo.

Agora, sejam $i \in [n-1]$ e $j \in [m-1]$ quaisquer, vamos provar que $A[i][j] + A[i+a][j+b] \leq A[i][j+b] + A[i+a][j]$ para todo $0 < a \leq n-i$ e $0 < b \leq m-j$ por indução em b . A base desta indução, onde $b=1$, foi provada no parágrafo anterior. Se $1 < b \leq m-j$ assumimos que a tese vale para $b-1$, escrevemos $A[i][j] + A[i+a][j+b-1] \leq A[i][j+b-1] + A[i+a][j]$, pela prova do parágrafo anterior, vale $A[i][j+b-1] + A[i+a][j+b] \leq A[i][j+b] + A[i+a][j+b-1]$ e, mais uma vez, somando as duas equações provamos a desigualdade $A[i][j] + A[i+a][j+b] \leq A[i][j+b] + A[i+a][j]$. Com isso provamos que A é Monge convexa.

A prova para o caso côncavo segue análogamente. \square

As matrizes Monge são usadas para resolver uma série de problemas que serão explorados aqui. A condição de Monge é a mais forte apresentada neste trabalho e alguns dos algoritmos apresentados não dependem dela, apenas da monotonicidade ou total monotonicidade, ainda assim, ela leva a resultados úteis que nos permitem provar a pertinência dos algoritmos a problemas, mesmo que o algoritmo usado não se utilize da condição diretamente.

Como consequência desta utilidade, iremos discutir um problema que será resolvido com um algoritmo apresentado somente na Seção 4, o algoritmo SMAWK. Ele não será explicado neste momento, utilizamos ele como caixa preta. Desta forma, poderemos introduzir estes resultados que são importantes em vários momentos deste texto e na aplicação prática dos conhecimentos discutidos aqui de forma suave e motivada.

Problema 2.13. Definimos a função de custo c de cada vetor v como $c(v) =$

$$\left(\sum_{i=1}^{|v|} v_i \right)^2.$$

Dados dois inteiros k e n e um vetor $v \in \mathbb{Q}_+^n$, queremos particionar o vetor v em k subvetores de forma a minimizar a soma dos custos das partes. Formalmente, queremos escolher um particionamento P_1, P_2, \dots, P_k de v em subvetores que minimize $\sum_{i=1}^k c(v_{P_i})$.

Definimos a matriz A para todo $i, j \in [0..n]$ onde $A[i][j] = c(v[i+1..j])$ para todo $i \leq j$ e $A[i][j] = +\infty$ caso contrário. A matriz não precisa ser explicitamente calculada, pré-calculamos em $\mathcal{O}(n)$ o vetor a tal que $a_i = \sum_{k=1}^i v_k$ para todo $i \in [0..n]$. Com o vetor a conseguimos calcular cada entrada da matriz A em $\mathcal{O}(1)$ quando necessário.

Podemos resolver o Problema 2.13 com programação dinâmica. Um subproblema de parâmetros i e ℓ é da forma: Melhor particionamento do vetor $v[i+1..n]$ em ℓ partes. Definimos a matriz $E \in \mathbb{Q}^{[k] \times [0..n]}$ de respostas desses subproblemas, assim, se ℓ e i definem um subproblema o seu valor ótimo é guardado em $E[\ell][i]$. Todas as outras entradas da matriz E têm valor $+\infty$. Escrevemos E como uma recorrência, para todo $\ell \in [k]$ e $i \in [0..n]$,

$$E[\ell][i] = \begin{cases} A[i][n] & , \text{ se } \ell = 1, \\ \min_{j=i}^n A[i][j] + E[\ell-1][j] & , \text{ se } \ell \leq k \text{ e} \\ +\infty & , \text{ caso contrário.} \end{cases}$$

É fácil resolver a recorrência definida acima em tempo $\mathcal{O}(kn^2)$. Vamos simplificar a definição de E . Fixados $i \in [0..n]$ e $\ell \in [1..k]$, se $j < i$ então $A[i][j] = +\infty$ e podemos escrever $E[\ell][i] = \min_{j=0}^n A[i][j] + E[\ell-1][j]$. Definimos a matriz B_ℓ onde, para todo $j \in [0..n]$, a entrada $B_\ell[i][j] = A[i][j] + E[\ell-1][j]$. Além disso, definimos a matriz B_1

onde, para todo $i, j \in [0..n]$ vale $B_1[i][j] = A[i][j] + A[i][n]$. Note que $\min_{j=0}^n B_1[i][j] = A[i][i] + A[i][n] = A[i][n] = E[1][i]$. Desta forma, para todo $\ell \in [k]$ e $i \in [0..n]$ vale $E[\ell][i] = \min_{j=0}^n B_\ell[i][j]$.

Com esta formulação, reduzimos o problema original a encontrar os mínimos das linhas de B_ℓ para todo $\ell \in [k]$. O algoritmo SMAWK encontra mínimos de linhas de matrizes $n+1 \times n+1$ totalmente monótonas por linhas em tempo $\mathcal{O}(n)$. Vamos mostrar que as matrizes B_ℓ são totalmente monótonas convexas por linhas para podermos aplicar o SMAWK.

Lema 2.14. *Sejam $A, B \in \mathbb{Q}^{n \times m}$ matrizes e $c \in \mathbb{Q}^m$ um vetor tais que para todo $i \in [n]$ e $j \in [m]$, $B[i][j] = A[i][j] + c[j]$. Se A é Monge convexa, B é Monge convexa.*

O mesmo resultado vale se $c \in \mathbb{Q}^n$ e $B[i][j] = A[i][j] + c[i]$. Os resultados análogos valem nos casos de concavidade.

Demonstração. Sejam A, B e b definidos como no enunciado do teorema. Suponha que A é Monge convexa. Vale, para quaisquer $1 \leq i < i' \leq n$ e $1 \leq j < j' \leq m$, $A[i][j] + A[i'][j'] \leq A[i'][j] + A[i][j']$, logo, vale $A[i][j] + b[j] + A[i'][j'] + b[j'] \leq A[i'][j] + b[j'] + A[i][j'] + b[j]$ que é $B[i][j] + B[i'][j'] \leq B[i'][j] + B[i][j']$. A prova para o caso onde $c \in \mathbb{Q}^n$ e $B[i][j] = A[i][j] + c[i]$ é análoga, bem como as provas para os casos côncavos. \square

Suponha que A é Monge convexa. Todas as matrizes B_ℓ se encaixam perfeitamente nas hipóteses do Lema 2.14 e, por isso, são Monge convexas, portanto, totalmente monótonas convexas por linhas. Basta provar que A é Monge convexa.

Teorema 2.15. *Sejam $A \in \mathbb{Q}^{n \times n}$ uma matriz, $w \in \mathbb{Q}_+^n$ um vetor e $g: \mathbb{Q} \rightarrow \mathbb{Q}$ uma função tais que para todo $i, j \in [n]$ vale $A[i][j] = g\left(\sum_{k=1}^j w_k - \sum_{k=1}^i w_k\right)$. Se g é convexa, A é Monge convexa. Similarmente, se g é côncava, A é Monge côncava.*

Antes de demonstrar este teorema, vamos provar que A é Monge convexa utilizando o resultado. Considere a função g tal que $g(x) = x^2$ se $x \geq 0$ e $g(x) = +\infty$ caso contrário. Vale, para todo $i, j \in [n]$, $A[i][j] = g\left(\sum_{k=1}^j v_k - \sum_{k=1}^i v_k\right)$. Vamos provar que g é convexa. Sejam $x \leq y \in \mathbb{Q}$ e $\lambda \in [0, 1]$, escrevemos $z = \lambda x + (1 - \lambda)y$. Se $0 \leq x$, pela Proposição 2.3, sabemos $g(z) \leq \lambda g(x) + (1 - \lambda)g(y)$. Se $x < 0$, vale $\lambda g(x) + (1 - \lambda)g(y) = +\infty \geq g(z)$, independente do valor de $g(z)$. Assim, g é convexa e aplicamos o teorema para concluir que A é Monge convexa.

Com isso já que o nosso problema se reduziu a encontrar, para todos os $\ell \in [k]$ os mínimos das linhas da matriz B_ℓ e estas são Monge convexas, elas também são totalmente monótonas convexas por linhas e podemos encontrar seus máximos em $\mathcal{O}(n)$, resolvendo o problema todo em $\mathcal{O}(kn)$.

Nos falta provar o Teorema 2.15.

Demonstração. Sejam A e g quaisquer que respeitem as condições do enunciado. Sejam ainda $i, i', j, j' \in [n]$ onde $i < i'$ e $j < j'$. Escrevemos $a = \sum_{k=1}^{i'} w_k - \sum_{k=1}^i w_k$, $b = \sum_{k=1}^{j'} w_k - \sum_{k=1}^j w_k$ e $z = \sum_{k=1}^j w_k - \sum_{k=1}^{i'} w_k$. Desta forma, temos $g(z) = A[i'][j]$, $g(z + a + b) = A[i][j']$, $g(z + a) = A[i][j]$ e $g(z + b) = A[i'][j']$, portanto, $g(z + a) + g(z + b) \leq g(z) + g(z + a + b)$ se e somente se $A[i][j] + A[i'][j'] \leq A[i][j'] + A[i'][j]$ (A é Monge convexa).

Consideramos o caso onde $0 < a \leq b$. Temos $0 < a \leq b < a + b$, ou seja, $z < z + a \leq z + b < z + a + b$. Definimos $\lambda = \frac{a}{a+b}$. Já que $z + a = \lambda z + (1 - \lambda)(z + a + b)$ e $z + b = (1 - \lambda)z + \lambda(z + a + b)$, por convexidade de g , obtemos $g(z + a) \leq \lambda g(z) + (1 - \lambda)g(z + a + b)$ e $g(z + b) \leq \lambda g(z + a + b) + (1 - \lambda)g(z)$. Somando, obtemos $g(z + a) + g(z + b) \leq g(z) + g(z + a + b)$.

Se considerarmos o caso onde $0 < b \leq a$, seguimos o mesmo raciocínio e obtemos, novamente, $g(z + a) + g(z + b) \leq g(z) + g(z + a + b)$. Falta considerar o caso onde $0 = a = b$, neste caso, $g(z) = g(z + a) = g(z + b) = g(z + a + b)$ e vale $(z + a) + g(z + b) \leq g(z) + g(z + a + b)$. Portanto, A é Monge convexa. \square

3. DIVISÃO E CONQUISTA

Nesta seção será apresentada uma técnica que chamamos de Divisão e Conquista. A ideia é citada por Aggarwal [3] e é um tópico recorrente em competições de programação, sendo conhecida como “Divide and Conquer Optimization” [1] [2] e geralmente aplicada a problemas de programação dinâmica.

Além disso, as hipóteses deste algoritmo são mais fracas do que as do algoritmo SMAWK, apresentado na Seção 4, portanto, todo problema para o qual aquela solução pode ser aplicada, esta também pode. Ao final desta seção, apresentamos exemplos de aplicações em programação dinâmica.

Dada uma matriz $A \in \mathbb{Q}^{n \times m}$, listamos os casos de uso deste algoritmo:

- Se A é monótona nos mínimos das linhas podemos encontrar os índices de mínimos das linhas em tempo $\mathcal{O}((n + m) \lg(n))$,
- se A é monótona nos máximos das linhas podemos encontrar os índices de máximos das linhas em tempo $\mathcal{O}((n + m) \lg(n))$,
- se A é monótona nos mínimos das colunas podemos encontrar os índices de mínimos das colunas em tempo $\mathcal{O}((n + m) \lg(m))$ e
- se A é monótona nos máximos das colunas podemos encontrar os índices de máximos das colunas em tempo $\mathcal{O}((n + m) \lg(m))$.

Apresentaremos o caso em que A é crescente nos mínimos das linhas. É fácil manipular o algoritmo para trabalhar com os outros casos.

3.1. Técnica. Dada uma matriz $A \in \mathbb{Q}^{n \times m}$ monótona crescente nos mínimos das linhas, queremos encontrar o vetor de índices de mínimos das linhas de A . Isto é, para todo $i \in [n]$, queremos encontrar

$$R[i] = \min\{j \mid A[i][j] \leq A[i][j'] \text{ para todo } j' \in [n]\}.$$

Se, para alguma linha i , encontrarmos o valor $R[i]$, sabemos que para todo $i' < i$, $R[i'] \leq R[i]$ e, para todo $i' > i$, $R[i'] \geq R[i]$, isto é, sabemos que os mínimos de menor índice das outras linhas se encontram nas submatrizes $A[1 \dots i-1][1 \dots R[i]]$ e $A[i+1 \dots n][R[i] \dots m]$. Seguindo o paradigma de divisão e conquista, vamos resolver o mesmo problema para estas submatrizes e, conseqüentemente, resolver o problema original.

Algoritmo 3.1 Mínimos das linhas com divisão e conquista

- 1: **função** FINDROWMIN_DC(A, r_s, r_t, c_s, c_t)
 - 2: $\ell \leftarrow \lceil (r_s + r_t)/2 \rceil$
 - 3: $R[\ell]$ índice de mínimo da linha ℓ .
 - 4: **se** $i > r_s$ **então**
 - 5: $R[r_s \dots \ell - 1] \leftarrow \text{FINDROWMIN_DC}(A, r_s, \ell - 1, c_s, R[\ell])$
 - 6: **se** $i < r_t$ **então**
 - 7: $R[\ell + 1 \dots r_t] \leftarrow \text{FINDROWMIN_DC}(A, \ell + 1, r_t, R[\ell], c_t)$
 - 8: **devolve** R
-

Note que na linha 3 o mínimo só precisa ser buscado entre os índices c_s e c_t , inclusive, pois estamos resolvendo o problema para a submatriz $A[r_s \dots r_t][c_s \dots c_t]$.

3.2. Análise. Será feita uma análise do tempo de execução do algoritmo acima no pior caso assumindo que as atribuições feitas nas linhas 5 e 7 custam tempo constante, futuramente, na Subseção 3.3, iremos apresentar uma implementação em C++ que está de acordo com a análise realizada.

Se A é uma matriz e r_s, r_t, c_s e c_t são índices tais que $r_t - r_s = n > 0$ e $c_t - c_s = m > 0$, o tempo gasto por `FINDROWMIN_DC`(A, r_s, r_t, c_s, c_t) pode ser expresso pela seguinte recorrência:

$$T(n, m) = \begin{cases} m & , \text{ se } n = 1, \\ m + \max_{j \in [m]} T(1, j) & , \text{ se } n = 2, \\ m + \max_{j \in [m]} \left\{ T(\lceil n/2 \rceil - 1, m - j + 1) + T(\lfloor n/2 \rfloor, j) \right\} & , \text{ caso contrário.} \end{cases}$$

Proposição 3.2. *Para todo $n, m \geq 1$, $T(n, m) \leq (m+n) \lg(2n)$ e, portanto, a técnica da divisão e conquista consegue encontrar o mínimo de todas as linhas em tempo $\mathcal{O}((m+n) \lg(n))$*

Demonstração. Vamos usar indução em n para provar a tese. Se $n = 1$ e $m \geq 1$, $T(1, m) = m \leq (m+1) \lg(2)$. Se $n = 2$ e $m \geq 1$, existe $j \in [m]$ tal que $T(2, m) = m + r \leq 2m \leq (m+2) \lg(4)$. Agora, se $n \geq 3$ e $m \geq 1$, existe um $j \in [m]$ tal que

$$T(n, m) = m + T(\lceil n/2 \rceil - 1, j) + T(\lfloor n/2 \rfloor, m - j + 1).$$

Assumimos para $1 \leq n' < n$ e $m' \geq 1$ que $T(n', m') \leq (m' + n') \lg(2n')$. Com isso, já que $1 \leq \lceil n/2 \rceil - 1 < n$, $1 \leq \lfloor n/2 \rfloor < n$, $j \geq 1$ e $m - j + 1 \geq 1$, temos, com a equação acima e o fato de que $\lceil n/2 \rceil - 1 \leq \lfloor n/2 \rfloor \leq n/2$,

$$\begin{aligned} T(n, m) &\leq m + (j + \lceil n/2 \rceil - 1 + m - j + 1 + \lfloor n/2 \rfloor) \lg(n) \\ &= m + (m+n) \lg(n) < (m+n)(\lg(n) + 1) = (m+n) \lg(2n). \end{aligned}$$

□

3.3. Implementação. Para implementar o Algoritmo 3.1 com a complexidade desejada, devemos tomar cuidado com as atribuições feitas nas linhas 5 e 7. A forma como elas foram apresentadas sugere que os vetores R recebidos pelas funções sejam recebidos e copiados para o vetor R . Ao invés de fazer isso, passaremos o endereço do vetor R recursivamente e garantir que cada chamada só complete o subvetor $R[r_c \dots r_t]$, referente a seu subproblema. Além disso, como explicado na Subseção 1.2, a matriz A será passada como uma função e não como uma matriz.

A implementação em C++ do algoritmo apresentado, levando em conta as considerações acima, pode ser encontrada em `implementacao/FindRowMax_DC.cpp`.

3.4. Aplicação em programação dinâmica. Utilizaremos a técnica apresentada aqui para resolver uma adaptação do problema “Internet Trouble” da Final Brasileira da Maratona de Programação de 2016. A prova em questão pode ser encontrada no link <http://maratona.ime.usp.br/hist/2016/resultados/contest.pdf>.

Problema 3.3. Definimos a função de custo c de cada vetor v como $c(v) =$

$$\sum_{i=1}^{|v|} \min(i-1, m-i)v_i.$$

Sejam n e k inteiros onde $1 \leq k \leq n$ e seja $h \in \mathbb{N}^n$ um vetor, queremos encontrar uma partição P de h em até k subvetores $h_{P_1}, h_{P_2}, \dots, h_{P_k}$ não vazios de forma que $\sum_{i=1}^k c(h_{P_i})$.

Podemos dar ao problema acima a interpretação do problema “Internet Trouble” citado. Temos várias cidades dispostas em uma linha e queremos escolher $k+1$ destas cidades para instalar torres de distribuição de energia de forma a minimizar o custo de alimentar todas as cidades com energia. Nesta adaptação, as cidades 1 e n são escolhas obrigatórias. Se na cidade de índice i existem h_i habitantes, o custo de transferir energia de uma torre a d cidades de distância para esta cidade é dado por dh_i . Note que, se há uma torre na própria cidade, o custo é considerado 0.

Definimos, para todo $1 \leq i \leq j \leq n$ o custo $A[i][j]$ de escolher o subvetor $v[i..j]$ como uma das partições. Os valores com índices de linhas maiores do que índices de colunas não fazem sentido na nossa modelagem, portanto, queremos torná-los inválidos, já o problema é de minimização definimos seus valores como $+\infty$. Assim, para todo $1 \leq i, j \leq n$,

$$A[i][j] = \begin{cases} c(v[i..j]) & , \text{ se } i \leq j \text{ e} \\ +\infty & , \text{ c.c.} \end{cases}$$

Perceba que, se criarmos em tempo $\mathcal{O}(n)$ dois vetores $p, q \in \mathbb{N}^{[0..n]}$ onde, para todo $i \in [0..n]$, $p_i = \sum_{k=1}^i v_k$ e $q_i = \sum_{k=1}^i kv_k$, podemos calcular cada entrada de A em $\mathcal{O}(1)$ quando necessário.

Queremos resolver o problema com programação dinâmica. Definimos para todo $\ell \in [k]$ e $i \in [n]$ com $\ell \leq n-i+1$ o problema de encontrar o melhor particionamento do subvetor $v[i..n]$ em ℓ partes. Definimos como $E[\ell][i]$ o valor ótimo atingido neste subproblema. Se $\ell = 1$, escrevemos $E[\ell][i] = A[i][n]$ e se $1 < \ell \leq k$ escrevemos $E[\ell][i] = \min_{j=i}^{n-\ell+2} A[i][j] + E[\ell-1][j]$. Esta recorrência define um programa dinâmico que pode ser resolvido trivialmente em tempo $\mathcal{O}(kn^2)$.

Com $\ell > 1$, definindo $B_\ell[i][j] = A[i][j] + E[\ell-1][j]$ podemos reescrever $E[\ell][i] = \min_{j=i}^{n-\ell+2} B_\ell[i][j]$ e, se definirmos $B_\ell[i][j] = +\infty$ para todo i que

desrespeite $i \leq j$ ou $\ell \leq n - i + 1$, teremos $E[\ell][i] = \min_{j=1}^n B_\ell[i][j]$. Esta formulação reduz o problema de programação dinâmica a encontrar, para todo $1 < \ell \leq k$ fixo, os mínimos das linhas da matriz B_ℓ . Com isso, basta provar que B_ℓ é monótona crescente nos mínimos das linhas e aplicar a técnica da divisão e conquista para resolver o problema em tempo $\mathcal{O}(kn \log(n))$.

Vamos, primeiramente, provar que A é Monge convexa. Queremos mostrar que vale, para todo $i, j \in [n]$, a desigualdade $A[i][j] + A[i+1][j+1] \leq A[i][j+1] + A[i+1][j]$ e usar o Teorema 2.12 para concluir que A é Monge convexa. Se $j \leq i$, $A[i+1][j] = +\infty$, logo, já que $A[i][j+1] \geq 0$, a desigualdade vale. Consideramos que $i < j$. Escrevemos $a = \lfloor \frac{i+j}{2} \rfloor$ e $b = \lceil \frac{i+j}{2} \rceil$, note que $b = \lfloor \frac{i+j+1}{2} \rfloor$.

$$\begin{aligned} \text{Temos } A[i][j] &= \sum_{k=i}^j \min(k-i, j-k) h_k = \sum_{k=i}^a (k-i) h_k + \sum_{k=a+1}^j (j-k) h_k \\ \text{e } A[i][j+1] &= \sum_{k=i}^{j+1} \min(k-i, j-k+1) h_k = \sum_{k=i}^b (k-i) h_k + \sum_{k=b+1}^j (j-k+1) h_k. \end{aligned}$$

Se $i+j$ é par, $a = b$ e vale $A[i][j+1] = \sum_{k=i}^a (k-i) h_k + \sum_{k=a+1}^j (j-k) h_k =$

$$A[i][j] + \sum_{k=a+1}^j h_k. \text{ Se } i+j+1 \text{ é ímpar, } b-1 = a \text{ e } b = \frac{i+j+1}{2}, \text{ logo } b-i =$$

$$j-b+1 \text{ e teremos } (k-b) h_b = (j-b+1) h_b, \text{ o que leva a } A[i][j+1] =$$

$$\sum_{k=i}^a (k-i) h_k + \sum_{k=a+1}^j (j-k+1) h_k = A[i][j] + \sum_{k=a+1}^j h_k.$$

O parágrafo acima nos mostrou que $A[i][j+1] = A[i][j] + \sum_{k=a+1}^j h_k$. Com um raciocínio parecido, conseguiremos concluir $A[i+1][j+1] = A[i+1][j] + \sum_{k=b+1}^j h_k$. Assim, $A[i][j+1] - A[i+1][j+1] = A[i][j] + \sum_{k=a+1}^j h_k - A[i+1][j] - \sum_{k=b+1}^j h_k$. Sabemos que $a \leq b$, portanto, obtivemos $A[i][j+1] - A[i+1][j+1] \geq A[i][j] - A[i+1][j]$, isto é $A[i][j] + A[i+1][j+1] \leq A[i][j+1] + A[i+1][j]$. Provamos que A é Monge convexa.

Sabemos que A é Monge convexa, pelo Teorema 2.14 todas as matrizes B_ℓ são Monge convexas, portanto, monótonas decrescentes nos mínimos das linhas e podemos aplicar a técnica da Divisão e Conquista para encontrar seus mínimos de linhas em tempo $\mathcal{O}(n)$. Já que o problema consiste em encontrar estes mínimos para todas as matrizes B_ℓ com $\ell \in [k]$, conseguimos resolver o problema em tempo $\mathcal{O}(kn \lg(n))$. Vale notar que a Subseção 4.6 ensina a resolver este mesmo problema em tempo $\mathcal{O}(kn)$.

4. SMAWK

Nesta seção discutiremos o algoritmo SMAWK. Ele é conhecido pela sua aplicação no problema de encontrar o vértice mais distante de cada vértice num polígono convexo em tempo linear [3]. Ao final desta seção serão citadas esta e outras aplicações deste algoritmo.

Dada uma matriz $A \in \mathbb{Q}^{n \times m}$, listamos os casos de uso deste algoritmo:

- Se A é totalmente monótona convexa ou côncava nas linhas podemos encontrar os índices de mínimos e máximos das linhas em tempo $\mathcal{O}(n + m)$ e
- se A é totalmente monótona convexa ou côncava nas colunas podemos encontrar os índices de mínimos e máximos das colunas em tempo $\mathcal{O}(n + m)$.

Apresentaremos o caso onde A é totalmente monótona convexa nas linhas e estamos interessados nos índices de mínimos. É fácil manipular o algoritmo para trabalhar com os outros casos.

4.1. Técnica Primordial. Para facilitar a compreensão do algoritmo SMAWK, iremos apresentar uma técnica parecida com a Divisão e Conquista apresentada na Seção 3 e mostrar uma otimização desta técnica que leva ao algoritmo SMAWK.

Dada uma matriz $A \in \mathbb{Q}^{n \times m}$ totalmente monótona convexa por linhas, queremos encontrar o índice de mínimo de cada uma das linhas de A . Se para uma dada linha i onde $i > 0$ e $i < n$ conhecermos os índices ℓ e r de mínimos das linhas $i - 1$ e $i + 1$, respectivamente, já que A tem os índices de mínimos das linhas crescente (por ser totalmente monótona) basta buscar o índice de mínimo da linha i no intervalo entre ℓ e r (inclusive). Além disso, se i é a primeira linha da matriz podemos considerar $\ell = 1$ ou se i é a última linha da matriz podemos considerar $r = n$ sem perder a validade do fato de que basta buscar entre ℓ e r .

Após realizar as observações acima note que, já que A é totalmente monótona, remover qualquer linha de A mantém a total monotonicidade e não altera o índice de mínimo de outra linha. Com esta observação, concluímos que podemos remover todas as linhas pares da matriz, resolver o problema recursivamente para a matriz resultante e utilizar este resultado para calcular os índices de interesse para as linhas pares da matriz. Vamos provar que encontrar estes índices de mínimos custa tempo $\mathcal{O}(m)$.

Definimos a sequência t de forma que a i -ésima linha ímpar de A busca seu máximo entre as colunas t_{i-1} e t_i , inclusive. Sabemos que $0 = t_0 \leq t_1 \leq t_2 \leq \dots \leq t_{\lfloor n/2 \rfloor} \leq n$. Podemos escrever o tempo gasto por todas as

buscas de mínimo como $\sum_{i=1}^{\lfloor n/2 \rfloor} t_i - t_{i-1} + 1 = \mathcal{O}(n + m)$, ou seja, o trabalho feito para encontrar os mínimos das colunas ímpares dados os mínimos das colunas pares custa tempo $\mathcal{O}(n + m)$.

Agora, com uma análise similar à realizada para a técnica da Divisão e Conquista é fácil concluir que uma implementação desta técnica que consiga remover as linhas pares da matriz (e adicionar elas de volta) em tempo $\mathcal{O}(1)$ resolve o problema em tempo $\mathcal{O}((n + m) \lg(n))$, assim como a técnica da divisão e conquista.

4.2. Reduce. Chamamos de ótimas as células de uma matriz que são mínimo de alguma linha e as colunas que contém o índice de mínimo de pelo menos uma linha. Note que uma matriz contém no máximo n colunas ótimas, pois cada linha faz com que exatamente uma célula seja ótima.

Queremos agilizar a técnica apresentada acima. Para isso, vamos adicionar a nova hipótese de que a matriz A é quadrada, ou seja, $n = m$. Lembre que a cada passo, removemos as $\lfloor n/2 \rfloor$ linhas pares da matriz gerando uma nova matriz A' , resolvemos o problema recursivamente para A' e usamos a solução de A' para resolver para as linhas restantes de A . Quando removemos linhas da nossa A , ela deixa de ser quadrada e passa a ser uma matriz com mais colunas do que linhas, isto é, $m \geq n$. Queremos remover colunas não ótimas da matriz A com mais colunas do que linhas fazendo com que A se torne quadrada.

Vamos desenvolver o algoritmo REDUCE a partir de um índice de linha k e de algumas invariantes:

- (1) Vale $1 \leq k \leq n$,
- (2) apenas colunas não ótimas foram removidas da matriz e
- (3) toda célula em uma coluna de índice menor ou igual a k que possua índice de linha menor do que índice de coluna é não ótima. A Figura 4.1 representa, em azul, a célula de índice k, k e, em preto, as células que, segundo esta invariante, são não ótimas.




FIGURA 4.1. Invariante 3 do REDUCE.

Vamos comparar $A[k][k]$ com $A[k][k+1]$ e considerar dois casos. Em cada um dos casos, concluiremos que algumas células da matriz A são não ótimas. A Figura 4.2 mostra, hachuradas em vermelho, as células que são descobertas não ótimas quando $A[k][k] > A[k][k+1]$ e, com linhas verticais verdes, as células que são descobertas não ótimas quando $A[k][k] \leq A[k][k+1]$. Vamos provar estas implicações.

Se $A[k][k] > A[k][k+1]$, as entradas com índice de linha maior ou igual a k na coluna k são não ótimas. Primeiramente, a célula (k, k) é não ótima como consequência direta da desigualdade. Agora, suponha que existe alguma




FIGURA 4.2. Casos do REDUCE.

linha $i > k$ tal que $A[i][k] \leq A[i][k+1]$. Pela total monotonicidade convexa por linhas de A , isso implica em $A[k][k] \leq A[k][k+1]$, um absurdo.

Se $A[k][k] \leq A[k][k+1]$, as células da coluna $k+1$ com índices de linha menores ou iguais a k são não ótimas. A célula $(k, k+1)$ é não ótima pela desigualdade apresentada. Suponha que existe alguma linha $i < k$ tal que $A[i][k] > A[i][k+1]$. Pela contrapositiva da total monotonicidade, temos $A[k][k] > A[k][k+1]$, um absurdo.

Com estas observações estamos prontos para deduzir um algoritmo que elimina exatamente $m - n$ colunas de A .

Algoritmo 4.3 Algoritmo REDUCE

```

1: função REDUCE( $A$ )
2:    $k \leftarrow 1$ 
3:   enquanto  $A$  tem mais linhas do que colunas
4:     se  $A[k][k] > A[k][k+1]$  então
5:       Remove a coluna  $k$ 
6:        $k \leftarrow \max(1, k-1)$ 
7:     senão
8:       se  $k = n$  então
9:         Remove a coluna  $k+1$ 
10:      senão
11:         $k \leftarrow k+1$ 
12:   devolve  $A$ 

```

É fácil ver que as invariantes são válidas neste algoritmo. Olhamos para o primeiro passo, $k = 1$, nenhuma coluna foi removida ainda e não há elementos com índices de linha e coluna menores do que k , logo, as Invariantes 1, 2 e 3 valem. Em todo passo do loop, $A[k][k+1]$ existe, pois $k \leq n$ e $n \leq m$. Consideramos o caso onde $A[k][k] > A[k][k+1]$, a Invariante 1 sempre se mantém trivialmente, já provamos que a coluna k é não ótima neste caso, portanto, a Invariante 2 se mantém mesmo após a remoção da coluna k . Agora, se $k = 1$, vale a 3 por vacuidade e, no caso contrário, já que k decresce, a Invariante 3 também se mantém.

Em outro caso, valem $A[k][k] \leq A[k][k+1]$ e $k = n$. Foi provado que os elementos de linhas menores ou iguais a k na coluna $k+1$ são não ótimos, porém, isto representa toda a coluna $k+1$, assim, remover ela

mantém a Invariante 2. As outras duas invariantes se mantêm trivialmente. Agora, falta considerar o caso onde $A[k][k] \leq A[k][k+1]$ e $k < n$. Neste caso, foi provado, novamente, que as células com índices menores ou iguais a k na coluna $k+1$ são inválidos. Estes são exatamente os elementos com índices de linhas menores do que índices de colunas na coluna $k+1$, o que faz com que a Invariante 3 se mantenha ao incrementarmos o valor de k . As outras duas invariantes se mantêm trivialmente neste caso.

Além disso, o algoritmo, a cada passo, incrementa k ou remove uma coluna de A . Sabemos que k nunca passa de n e, já que a matriz tem m colunas, não podemos remover mais do que m colunas. Supondo que a cada remoção de coluna k seja decrementado, chegamos a uma quantidade máxima de $2m+n$ passos. Supondo que as remoções sejam feitas em tempo constante, o tempo de cada passo é constante, portanto, atingimos uma complexidade de $\mathcal{O}(m)$ operações no algoritmo REDUCE, já que $n \leq m$.

4.3. SMAWK. Recebemos uma matriz $A \in \mathbb{Q}^{n \times m}$ totalmente monótona convexa por linhas. Primeiramente, vamos transformar a matriz A em uma matriz quadrada. Se A tem mais colunas do que linhas, basta aplicar o algoritmo REDUCE em A para fazer com que ela fique quadrada e tenha os mesmos índices de mínimos. Se A tem mais linhas do que colunas, basta adicionar colunas sem que os mínimos ou a total monotonicidade sejam prejudicados, para isso, adicionamos, ao final da matriz, colunas $n-m$ com entradas infinitas.

Agora estamos prontos para descrever e aplicar o algoritmo SMAWK na matriz modificada. Vamos misturar as ideias apresentadas da técnica primordial, apresentada na Subseção 4.1, e do REDUCE, apresentado na Subseção 4.2. Em cada passo, removemos as linhas pares da matriz, aplicamos o algoritmo REDUCE para manter esta nova matriz quadrada e resolvemos o

Algoritmo 4.4 Algoritmo SMAWK

```

1: função SMAWK( $A$ )
2:   se  $A$  tem uma linha então
3:      $A$  é uma matriz  $1 \times 1$  e a resposta é trivial
4:   senão
5:     Retiramos as linhas pares de  $A$  gerando  $A'$ 
6:      $A'' \leftarrow \text{REDUCE}(A')$ 
7:     SMAWK( $A''$ )
8:     para  $i$  linha ímpar de  $A$  faça
9:        $l \leftarrow 1$  e  $r \leftarrow m$ 
10:      se  $i > 1$  então
11:         $l \leftarrow$  índice de mínimo da linha  $i-1$ 
12:      se  $i < n$  então
13:         $r \leftarrow$  índice de mínimo da linha  $i+1$ 
14:      Busca o índice de mínimo da linha  $i$  entre  $l$  e  $r$ , inclusive

```

problema recursivamente para a nova matriz. Com a solução desta instância, descobrimos os resultados para as linhas restantes da matriz original. O Algoritmo 4.4 descreve este processo.

4.4. Análise. O tempo gasto pelo algoritmo SMAWK depende apenas da dimensão n da matriz recebida. Escrevemos $T(n)$ a recorrência que define o tempo gasto pelo algoritmo para todo $n \geq 1$. Sabemos que $T(1) = \mathcal{O}(1)$. Com $n > 1$, a retirada de linhas pares será implementada em tempo constante, o algoritmo REDUCE é, então, aplicado a uma matriz com $\lfloor n/2 \rfloor$ linhas e n colunas, gastando tempo $\mathcal{O}(n)$ e depois os máximos das linhas ímpares de A são achados a partir das linhas pares de A na forma descrita na Subseção 4.1, o que custa tempo $\mathcal{O}(n)$. Assim, para todo $n > 1$, $T(n) = \mathcal{O}(n) + T(\lfloor n/2 \rfloor)$, o que nos leva a $T(n) = \mathcal{O}(n)$.

Se a matriz recebida tiver menos colunas do que linhas, a transformação inicial custa tempo $\mathcal{O}(n)$, no outro caso, custa tempo $\mathcal{O}(m)$, onde m é a quantidade de colunas. Assim, podemos escrever a complexidade no caso geral como $\mathcal{O}(n + m)$.

4.5. Implementação. Queremos encontrar uma maneira eficiente de remover as linhas pares da matriz, mas não podemos gerar explicitamente uma nova matriz. Queremos representar, a cada passo, todas as linhas que podem ser visitadas. Se k é um inteiro não negativo arbitrário, as linhas da matriz são da forma $1 + k$, as linhas visitáveis após a retirada de todas as pares são da forma $1 + 2k$, as visitáveis depois de duas remoções são da forma $1 + 4k$ e assim por diante, ou seja, depois de t remoções de linhas pares, podemos visitar as linhas da forma $1 + 2^t k$. Assim, basta guardar o inteiro $p = 2^t$ para representar todas as linhas que podem ser visitadas pelo algoritmo em um dado passo. Remover todas as linhas pares é dobrar o valor de p .

Agora, precisamos representar as colunas visitáveis em A . Já que não há uma regra fixa para a remoção de colunas, precisamos de alguma estrutura de dados que nos permita iterar pelos seus valores em ordem e remover um valor eficientemente sempre que visitado. Guardaremos uma lista duplamente ligada com todos os índices de colunas válidos, já que iteramos pelas colunas e, quando removemos uma coluna, ela é sempre vizinha da atual ou a atual, as remoções são feitas em $\mathcal{O}(1)$. Após resolver o problema recursivamente, precisamos recuperar as informações desta lista ligada ao início da iteração para podermos descobrir os valores de mínimo nas linhas ímpares daquela matriz, para isso, basta, ao começo de cada passo, criar uma cópia da lista ligada original, o que é feito em $\mathcal{O}(n)$ e não afeta a análise do tempo do algoritmo.

No início do algoritmo, precisamos gerar a lista ligada original e, caso haja mais colunas do que linhas, aplicar uma vez o algoritmo REDUCE. Caso a quantidade de linhas seja maior do que a de colunas, precisamos criar uma nova matriz com colunas a mais do que a original. Já que nossas matrizes são representadas por funções, suponha que o algoritmo recebe uma função f e dois inteiros n , quantidade de linhas, e m , quantidade de colunas. Podemos

criar uma função h definida, para todo $1 \leq i, j \leq n$ como $f(i, j)$ se $j \leq m$ e $+\infty$ caso contrário e substituir f por esta no restante do algoritmo.

A implementação em C++ do algoritmo apresentado, levando em conta as considerações acima, pode ser encontrada em `implementacao/SMAWK.cpp`.

4.6. Aplicações. O problema apresentado na Subseção 3.4 foi resolvido utilizando a técnica da divisão e conquista, porém, as matrizes para as quais aplicamos a técnica naquele exemplo são Monge convexas, portanto, totalmente monótonas convexas nas linhas, já que estávamos interessados em mínimos de linhas podemos aplicar o SMAWK ao invés da divisão e conquista para resolver estes problemas, conseguindo uma solução $\mathcal{O}(kn)$.

Como mencionado no início desta seção, a técnica apresentada aqui pode ser usada para resolver o problema de encontrar todos os pares de pontos mais distantes num polígono convexo em tempo $\mathcal{O}(n)$. Além disso, Aggarwal [3] mostrou a aplicação deste algoritmo em vários problemas de geometria computacional.

REFERÊNCIAS

- [1] <https://www.quora.com/What-is-divide-and-conquer-optimization-in-dynamic-programming>, May 2017.
- [2] <http://codeforces.com/blog/entry/8219>, May 2017.
- [3] Alok Aggarwal, Maria M. Klawe, Shlomo Moran, Peter Shor, and Robert Wilber. Geometric applications of a matrix-searching algorithm. *Algorithmica*, 2(1):195–208, 1987.
- [4] Wolfgang Bein, Mordecai J. Golin, Lawrence L. Larmore, and Yan Zhang. The knuth-yao quadrangle-inequality speedup is a consequence of total monotonicity. *ACM Trans. Algorithms*, 6(1):17:1–17:22, December 2009.
- [5] Peter Brucker. Efficient algorithms for some path partitioning problems. *Discrete Applied Mathematics*, 62(1):77 – 85, 1995.
- [6] Rainer E. Burkard, Bettina Klinz, and Rüdiger Rudolf. Perspectives of monge properties in optimization. *Discrete Applied Mathematics*, 70(2):95 – 161, 1996.
- [7] Mark De Berg, Marc Van Kreveld, Mark Overmars, and Otfried Cheong Schwarzkopf. Computational geometry. In *Computational geometry*, pages 1–17. Springer, 2000.
- [8] Zvi Galil and Kunsoo Park. Dynamic programming with convexity, concavity and sparsity. *Theoretical Computer Science*, 92(1):49 – 76, 1992.
- [9] D. E. Knuth. Optimum binary search trees. *Acta Informatica*, 1(1):14–25, 1971.
- [10] F. Frances Yao. Efficient dynamic programming using quadrangle inequalities. In *Proceedings of the Twelfth Annual ACM Symposium on Theory of Computing*, STOC ’80, pages 429–435, New York, NY, USA, 1980. ACM.